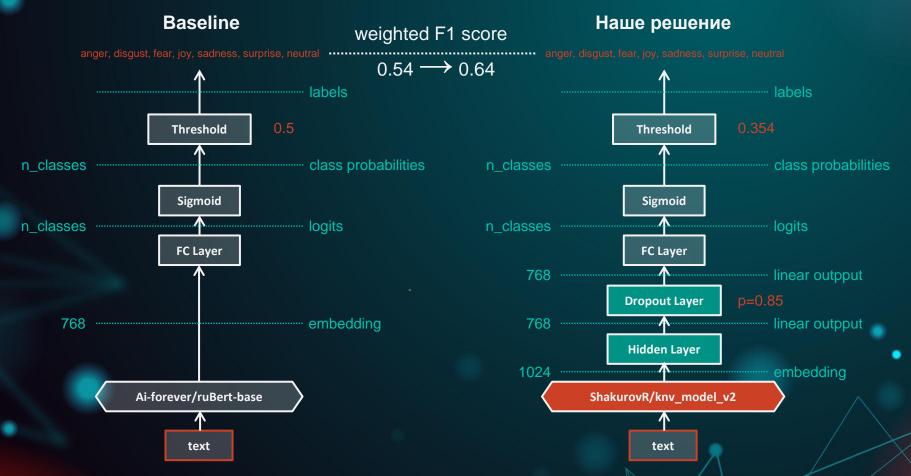


Задача

Задача партнера «Криптонит»

- Обучить языковую модель для классификации эмоций в текстах на русском языке
- Количество эмоций 7
- Один текст может содержать не одну эмоцию, а несколько

Решение

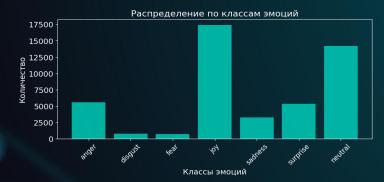


Расширение датасета

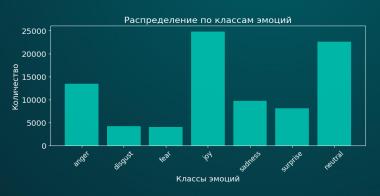
43,410 строк → 69,973 строки (+61%)



+ 24,891 строк из <u>ru-izard-emotions</u> + 700 строк fear и disgust с использованием LLM









Модель: какие пробовали

Nº	Модель(ссылка hf)	исследователь	orig data F1 val F1 sub	ext data F1 val F1 sub	F1(Submit)
1	https://huggingface.co/HIT-TMG/KaLM-embedding-multilingual-mini-instruct-v1	Даврон	0.64		
2	https://huggingface.co/Alibaba-NLP/gte-multilingual-base	Даврон	0.65		
3	https://huggingface.co/sismetanin/xlm_roberta_base-ru-sentiment-rusentiment	Марина	0.64		
4	https://huggingface.co/ai-forever/ruBert-large	Марина	0.66 0.55		
5	https://huggingface.co/badmatr11x/roberta-base-emotions-detection-from-text	Вероника	0.1476		
6	https://huggingface.co/DeepPavlov/distilrubert-tiny-cased-conversational	Вероника	0.5677		
7	https://huggingface.co/DeepPavlov/distilrubert-base-cased-conversational	Вероника	0.5909		
8	https://huggingface.co/ai-forever/ru-en-RoSBERTa	Михаил	0.672 0.593	0.6872	0.6412
9	https://huggingface.co/HIT-TMG/KaLM-embedding-multilingual-mini-instruct-v1	Михаил		0.6718	
10	https://huggingface.co/jinaai/jina-embeddings-v3	Михаил		0.5927	
11	https://huggingface.co/deepvk/USER-bge-m3	Михаил		0.6820	
12	https://huggingface.co/intfloat/multilingual-e5-large-instruct	Михаил		0.6851	
13	https://huggingface.co/ShakurovR/knv_model_v2_eager	Михаил		0.5999	
14	https://huggingface.co/sergeyzh/LaBSE-ru-turbo	Валентин	0.652		
15	https://huggingface.co/ShakurovR/knv_model_v2 + линейный слой+допаут(0.85)+подбор границы	Роман	0.685		0.642
16	https://huggingface.co/cointegrated/LaBSE-en-ru	Роман	0.6482		
17	https://huggingface.co/Geotrend/distilbert-base-ru-cased	Марина	0.61		
18	Модель из бейзлайна (ruBert_base) + emoji.demojize	Марина	0.65		
20	https://huggingface.co/cointegrated/rubert-base-cased-nli-threeway	Вероника	0.5797		
21	https://huggingface.co/cointegrated/rubert-tiny	Вероника	0.3716		
22	Модель из бейзлайна (ruBert_base) с балансировкой, аугментацией, ASR etc	Вероника	0.6210		

Модификация классификационной «головы»

Добавление второго линейного слоя

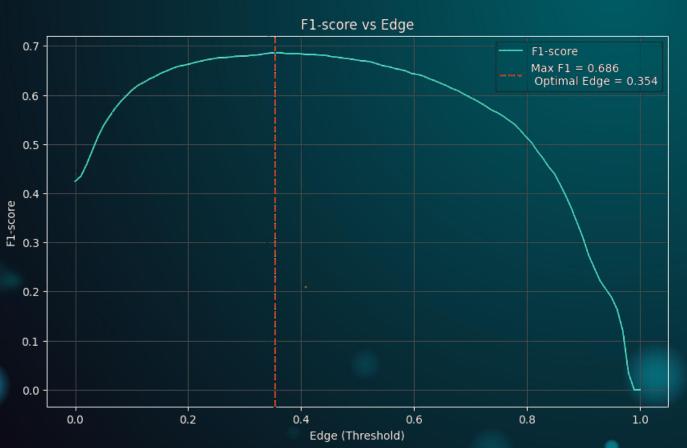


Добавление Dropout-слоя (0.85)



рост метрики и снижение переобучения

Эксперименты с порогом (threshold)



Эксперименты с размером скрытого слоя

Оптимальный размер скрытого слоя:

750-800

Слишком большой или слишком маленький размер уменьшает значение метрики weighted F1-score

Другие выводы и эксперименты

- Обработка эмодзи не повлияла на результат, потому что в тестовой выборке нет эмодзи 😟
- Балансировка весов классов в лоссфункции
- Замена sheduler для warmup на косинусный
- Замена функций активации на SiLu, GeLu, LeakyReLU
- Добавление слоев нормализации: LinearNorm, BatchNorm, GroupNorm

- Добавление нелинейности в классификационную голову
- Увеличение числа классификационных голов (от 2 до 7) с различным количеством нейронов и различными активациями
- Добавление мета-слоя, конкатенировавшего выходы классификационных голов
- Ручное добавление pooling-a и различные его варианты
- Добавление Residual-блоков

Идеи дальнейших исследований

1

Аугментация данных

2

Очистка и нормализация данных для инференса

3

Обработка ошибок ASR



Обработка эмодзи и эмотиконов